Casa abierta al tiempo

Universidad Autónoma Metropolitana
Unidad Iztapalapa

Maestría en Matemáticas Aplicadas e Industriales (MCMAI)

Proyecto final - Taller de modelado II Parte 1

Profesor: Dr. Alejandro Román Vásquez

Alumnos:

Brandon Eduardo Antonio Gómez

Alan Badillo Salas

01 de Julio de 2025

Contenido

1. Fase 1 - Adquisición de los datos

1.1. Objetivo

El objetivo del proyecto final consiste en aplicar la metodología sobre modelos de aprendizaje estadístico para construir un modelo de clasificación empleando el conjunto de datos **Adult**, en donde la predicción consiste en determinar si los ingresos de una persona superan los 50000 dólares al año.

1.2. Introducción

Al empezar con el pre-procesamiento de los datos nos percatamos de que falta el encabezado en la columnas, por lo que se agregamos los nombres de las columnas al dataframe.

El conjunto de datos contiene 32561 registros y 15 columnas (variables), las cuales son:

1. age: edad (numérico).
2. Worlclass, clase de trabajo: Privado,(categórico) Autónomo-no-inc, Autónomo-inc, Federal-gov, Local-gov, Estatal-without-pay, gov, (Sin sueldo, Nunca-trabajó.) (categórico)
3. fnlwgt: Final Weight. Es un peso de muestra (sampling weight) asignado por la Oficina del Censo de EE.UU. Se usa para extrapolar los datos de la muestra a toda la población estadounidense (numérico)
4. education: Bachelors, Some-college, 11th, HS-grad, Prof-school, Assoc-acdm, Assoc-voc, 9th, 7th-8th, 12th, Masters, 1st-4th, 10th, Doctorate, 5th-6th, Preschool. (categórico)
5. education-num: (numérico).
6. marital-status: Married-civ-spouse, Divorced, Never-married, Separated, Widowed, Married-spouse-absent, Married-AF-spouse.(categórico)
7. occupation: Apoyo técnico, Reparación artesanal, Otros servicios, Ventas, Directivo, Profesional especializado, Manipulador-limpiador, Operador de maquinaria, Administrativo, Agricultor-pescador, Transporte, Servicio doméstico privado, Servicio de protección, Fuerzas armadas.(categórico)
8. relationship (relación): Esposa, Hijo propio, Esposo, No familiar, Otro pariente, Soltero.(categórico)
9. race: Blanco, Asiático-Pacífico-Islandés, Amerindio-Esquimal, Otro, Negro.(categórico)
10. sex: Mujer, Hombre.(categórico)
11. capital-gain (plusvalía): (numérico)
12. capital-loss (minusvalía): (numérico)
13. Hours-per-week (horas-semana): (numérico).
14. native-country (país-nativo): Estados Unidos, Camboya, Inglaterra, Puerto Rico, Canadá, Alemania, EE.UU. periférico (Guam-USVI-etc.), India, Japón, Grecia, Sur, China, Cuba, Irán, Honduras, Filipinas, Italia, Polonia, Jamaica, Vietnam, México, Portugal, Irlanda, Francia, República Dominicana, Laos, Ecuador, Taiwán, Haití, Colombia, Hungría, Guatemala, Nicaragua, Escocia, Tailandia, Yugoslavia, El Salvador, Trinad & Tobago, Perú, Hong, Holanda. (categórico)
15. Income : ingreso (será la variable respuesta Y) (categórico)

Dado que la variable respuesta (Income) es categórica se trata de un problmea de clasificaciónñ, el eje de datos (Income) representa el ingreso ya sea que gane menos de 50000 dólares al año ($<= 50k$) o un ingreso mayor a 50000 dólares al año ($> 50k$)

Observamos que no hay valores faltantes, por lo que continuamos con el análisis

2. Ingeniería de Variables

En esta sección nos enfocamos en clasificar el tipo de datos, de los cuales hay 6 datos numéricos y 9 categóricos, para el eje de datos numéricos se realizan boxplot para ver si hay puntos atípicos y para los categóricos se realizan gaficas de barras.

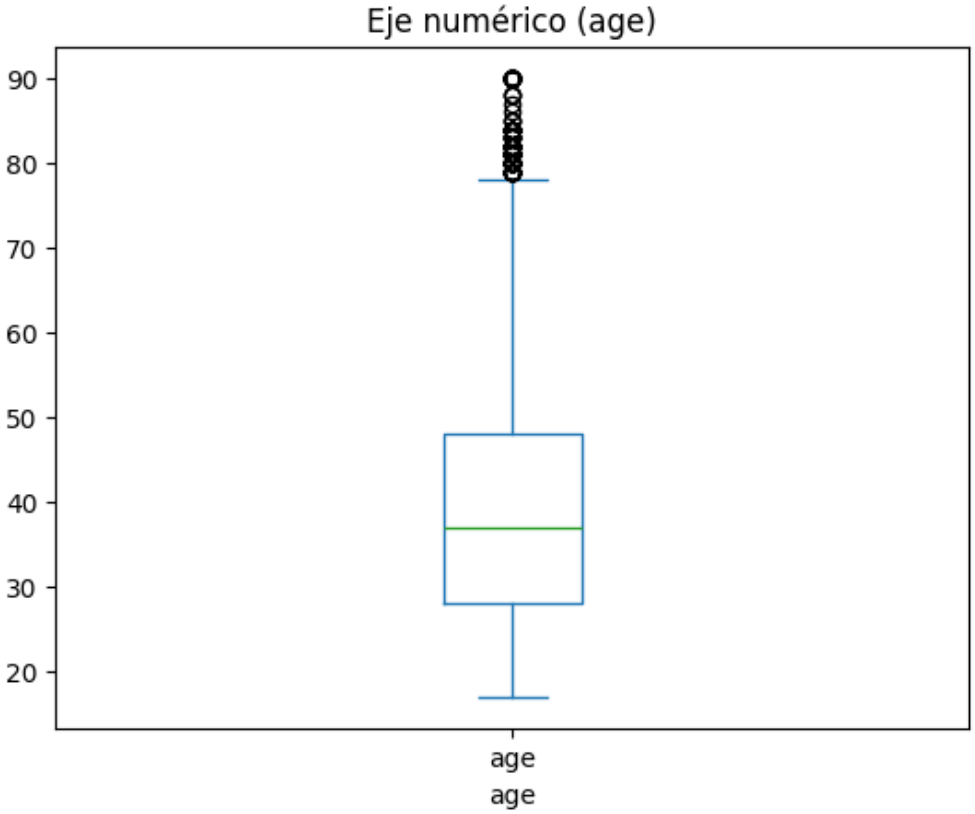

Podemos observar que este eje tiene datos atípicos (outliers) y podríamos estratificar la edad o tomarla como una variable continua o normalizada, por ejemplo, de la menor a la mayor edad o por segmentos de edades.

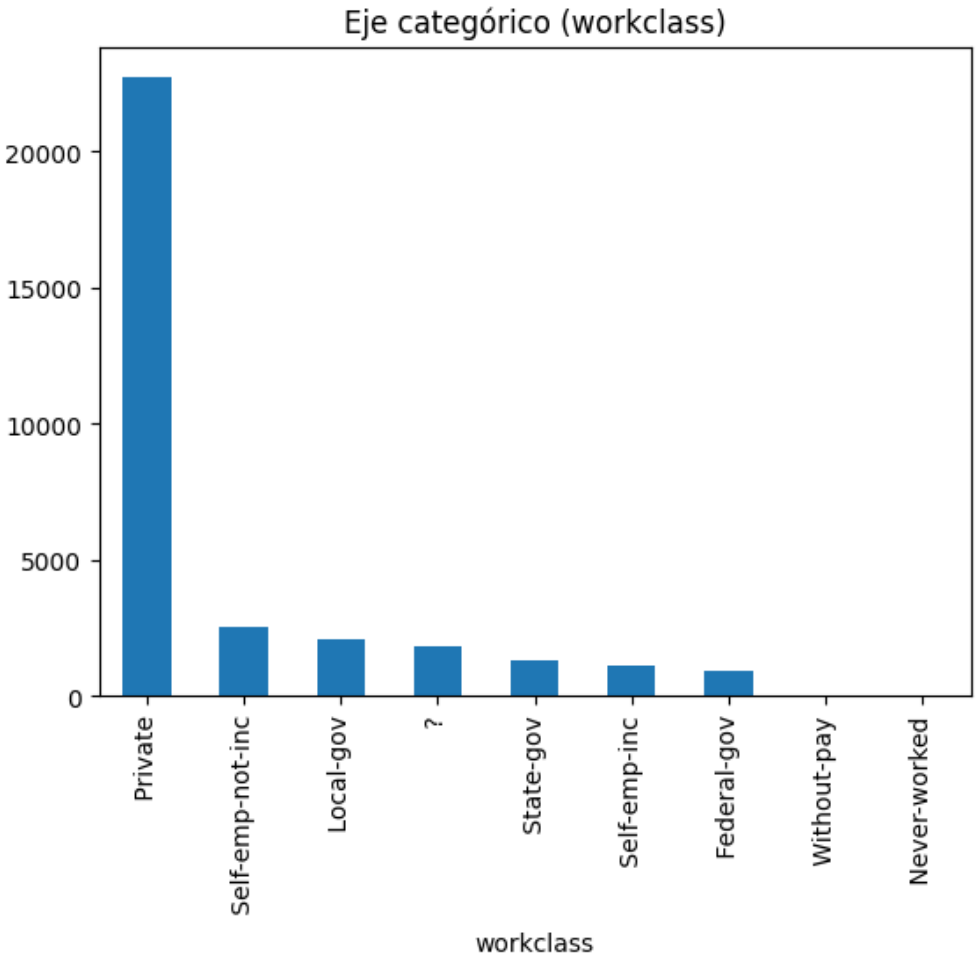

En tipo de trabajo observamos que la mayoría son del sector privado y los demás se dividen en los puestos gubernamentales, auto-empleados y que no trabajan. Además hay una categoría donde están los desconocidos (‘¿)

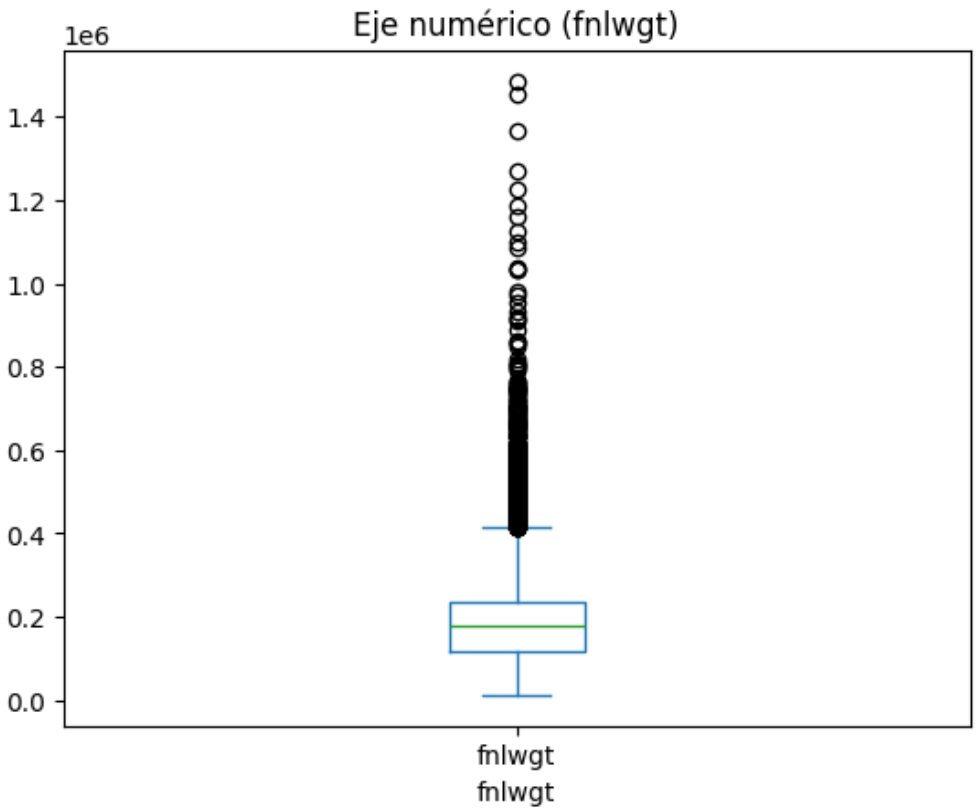

En este eje se observan bastantes datos atípicos.

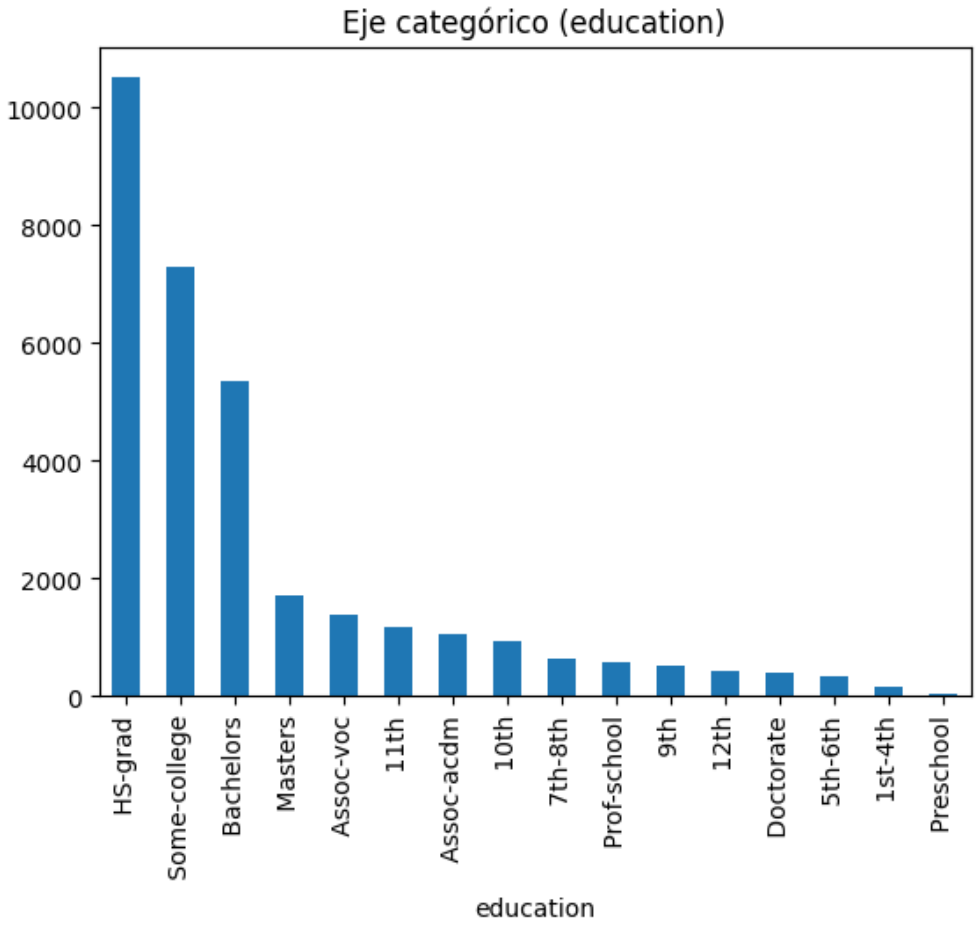

La categoría con mayor frecuencia son los que tienen educación media superior o preparatoria (HS-grad)

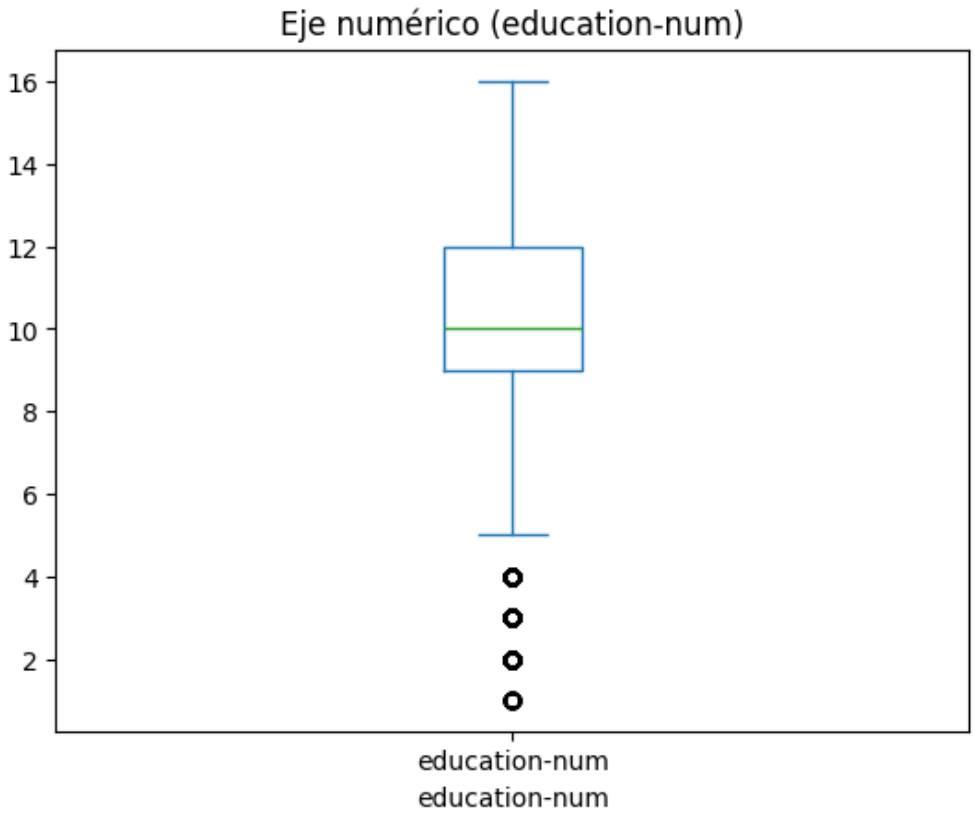
Eje numérico (education-num)
16
14
12
10
8
6
4
2
education-num
education-num

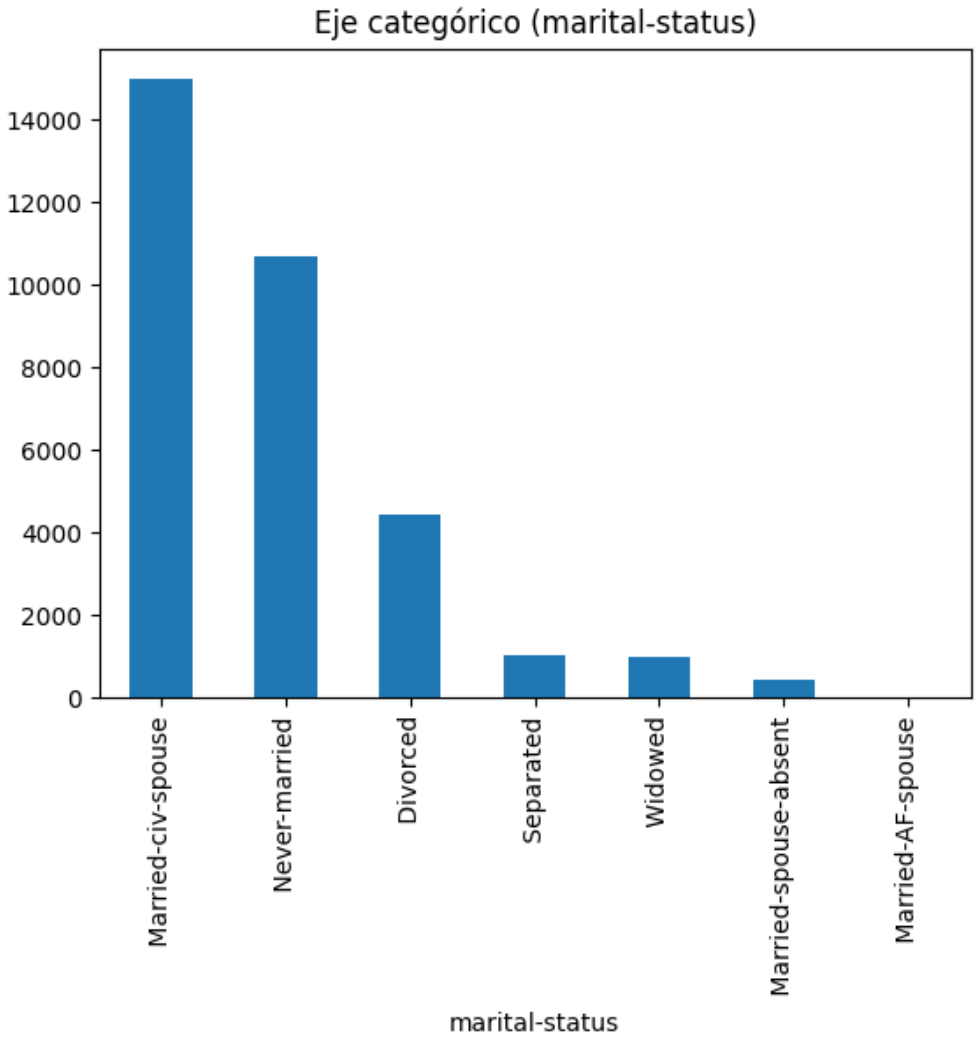

En el estado marital se observa que predominan los que están casados por el civil

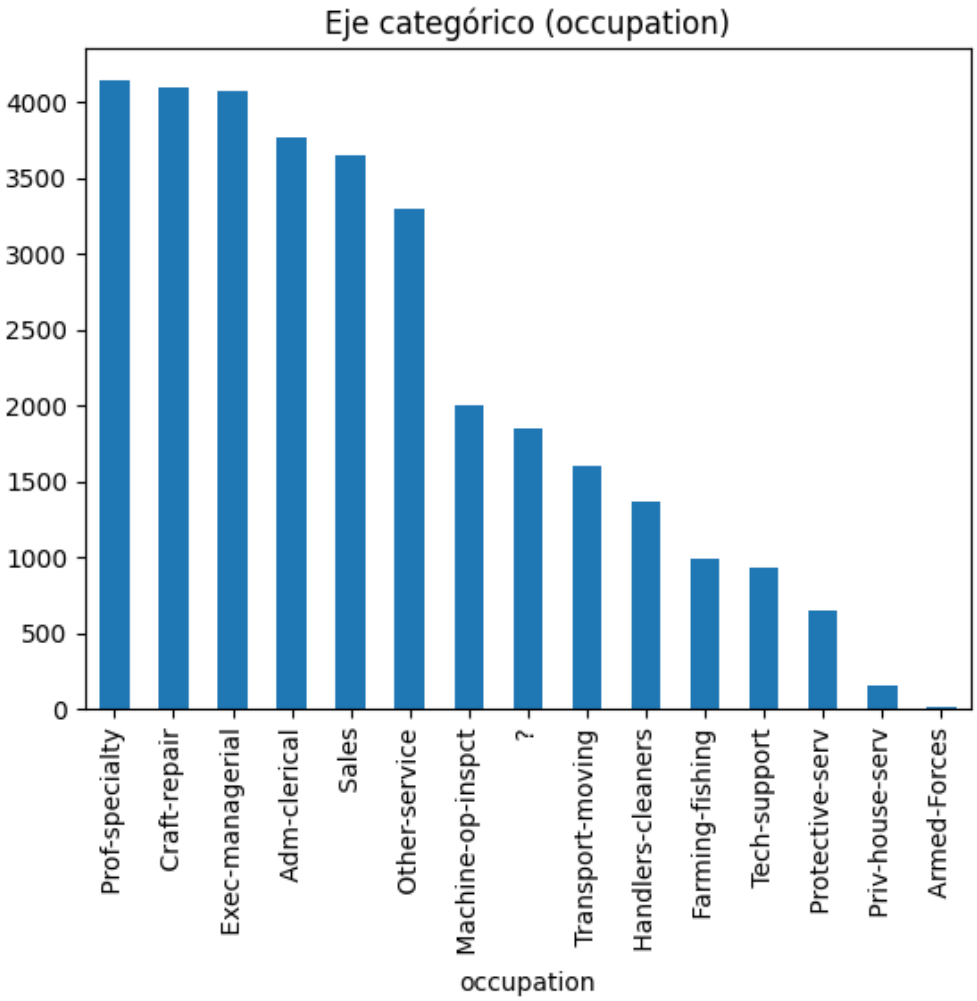
Eje categórico (occupation)
4000
3500
3000
2500
2000
1500
1000
500
0
Prof-specialty
Craft-repair
Exec-managerial
Adm-clerical
Sales
Other-service
Machine-op-inspct
?
Transport-moving
Handlers-cleaners
Farming-fishing
Tech-support
Protective-serv
Priv-house-serv
Armed-Forces
occupation

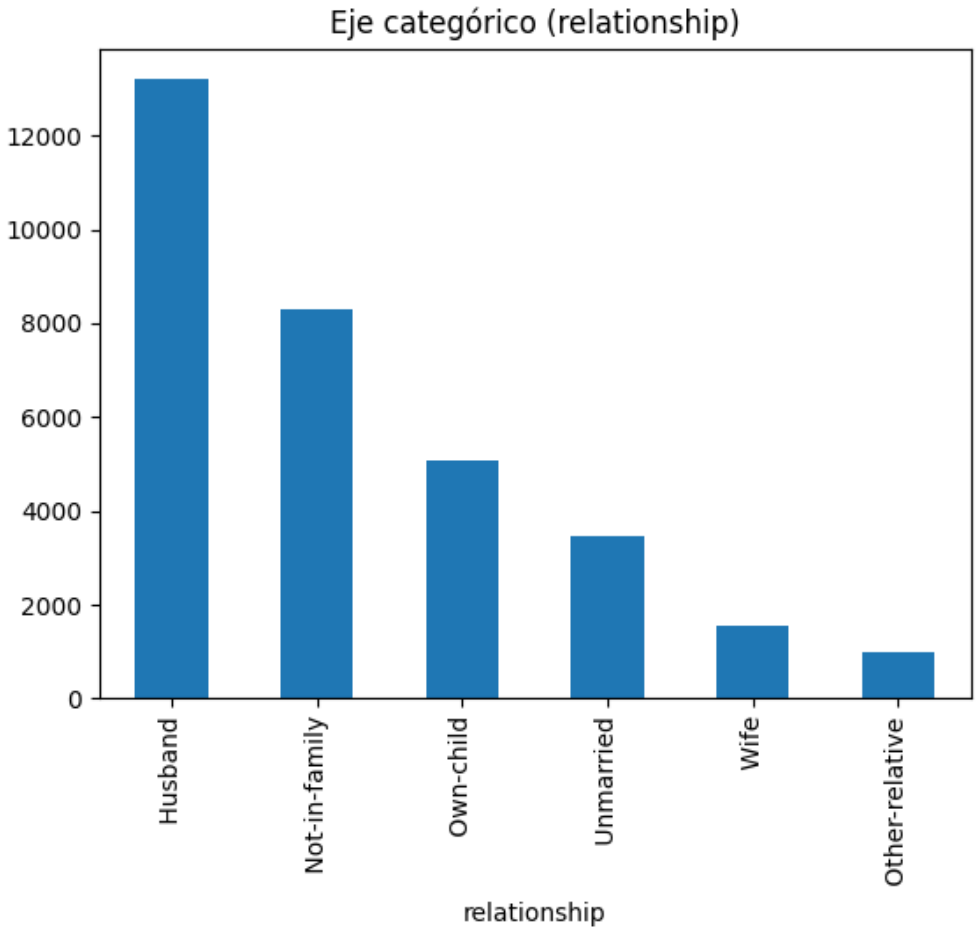

Observamos que predomina la categoría esposos.

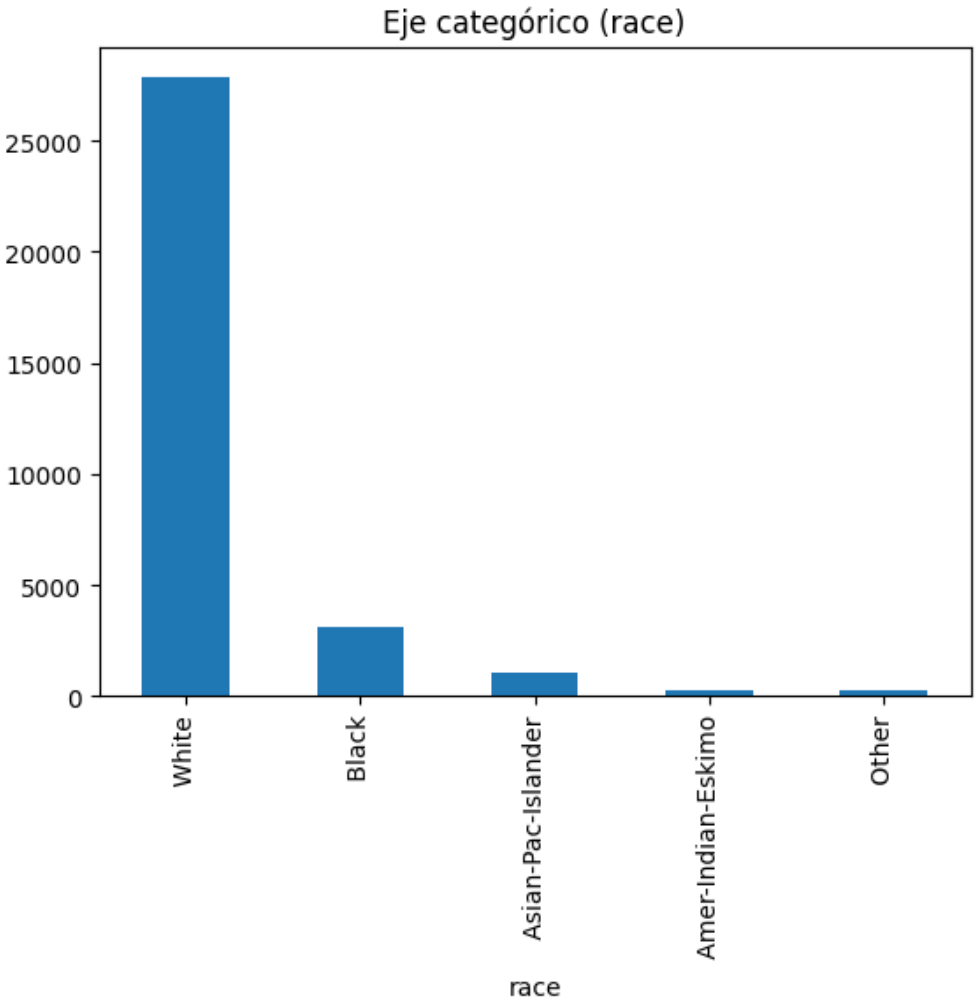

La mayoría de las personas son blancas

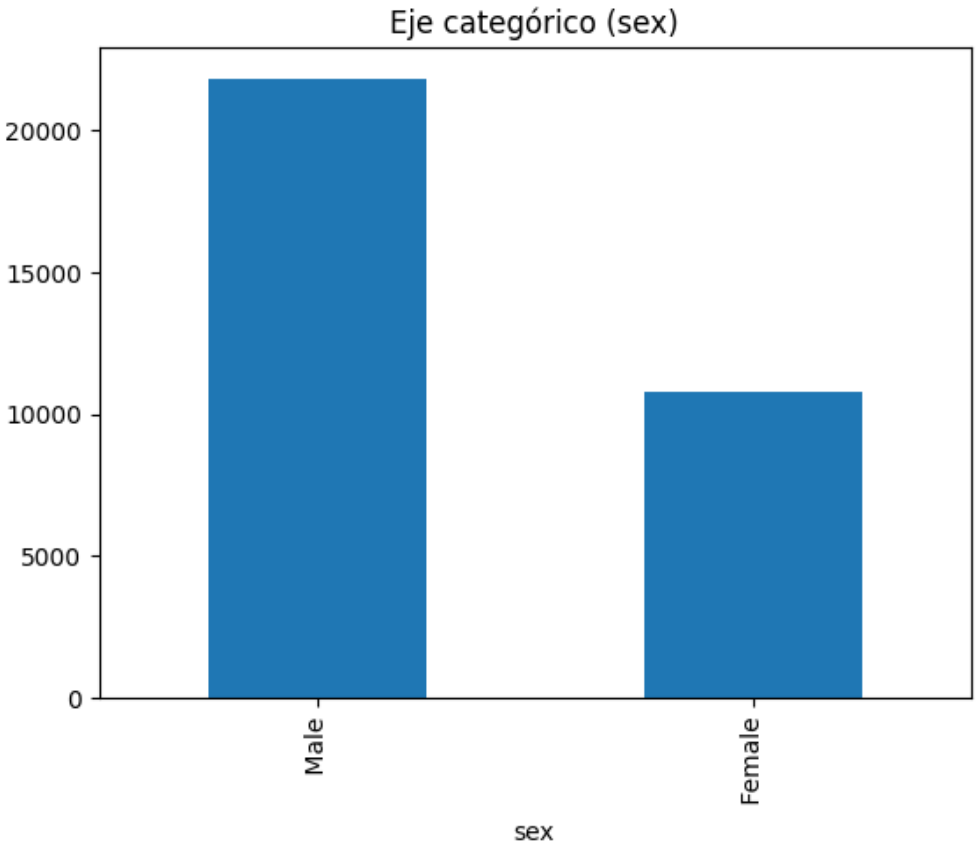

Se observa que son más hombres que mujeres, practicamente el doble.

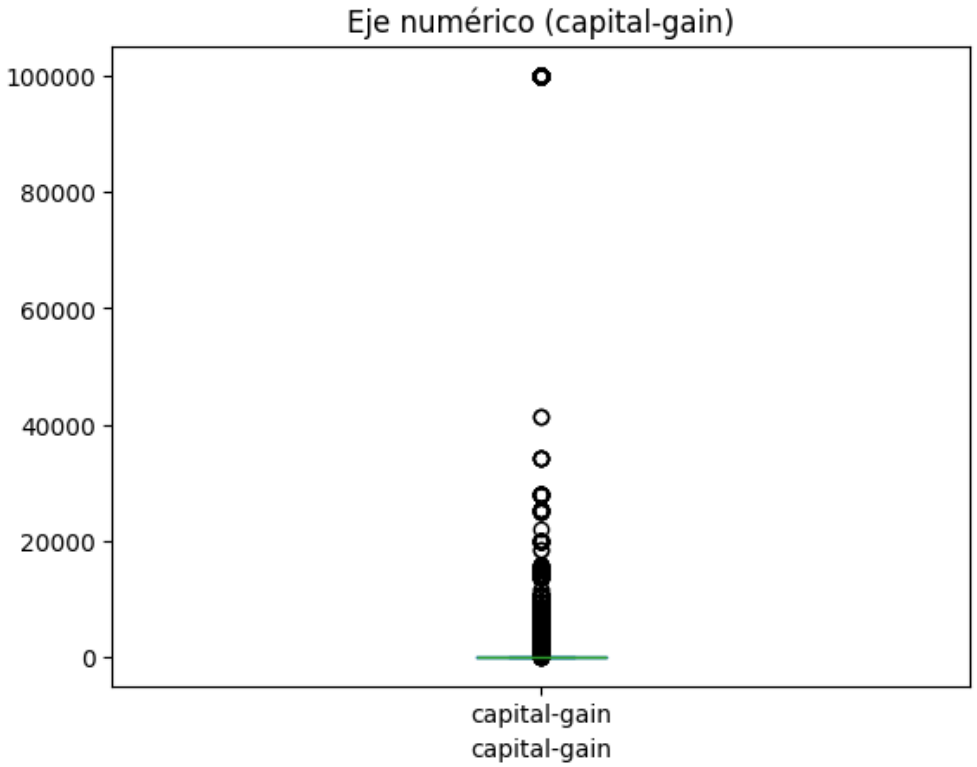

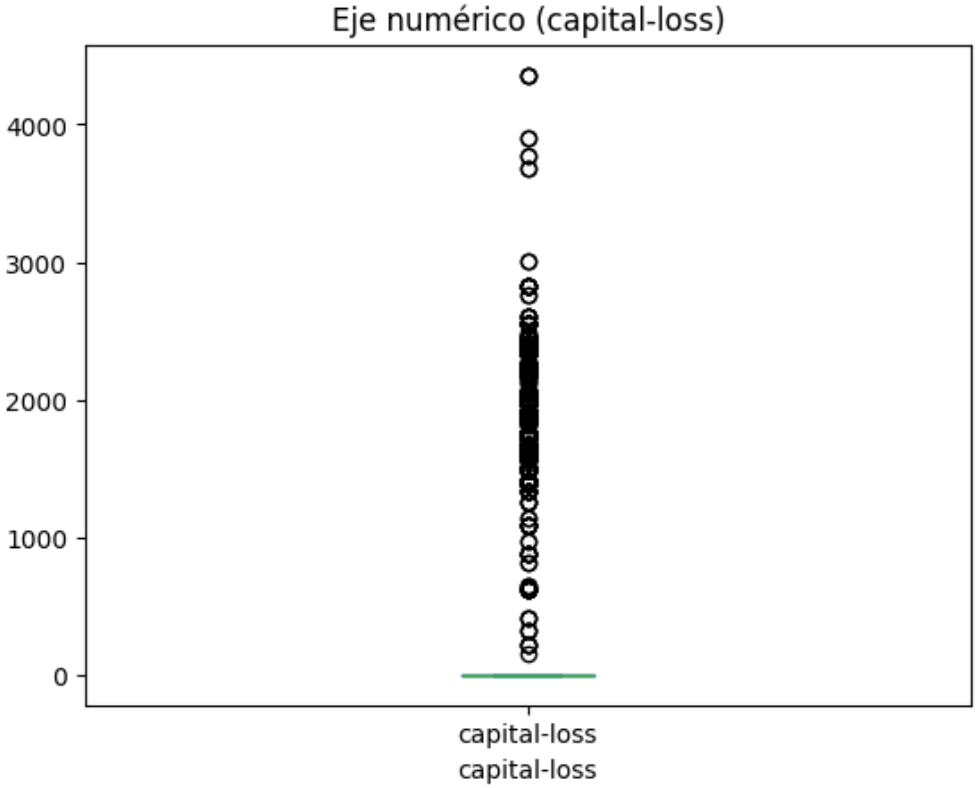

Tanto la plusvalía (capital-gain) como la minusvalía (capital-loss) tienen puntos atípicos

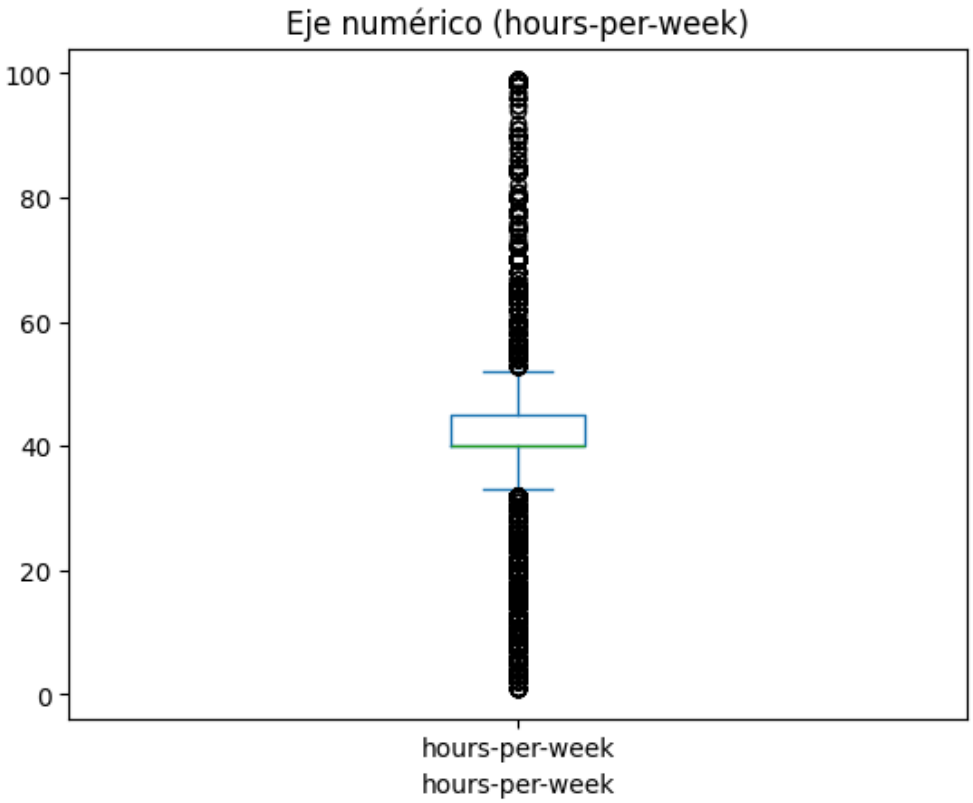
Eje numérico (hours-per-week)
100
80
60
40
20
0
hours-per-week
hours-per-week

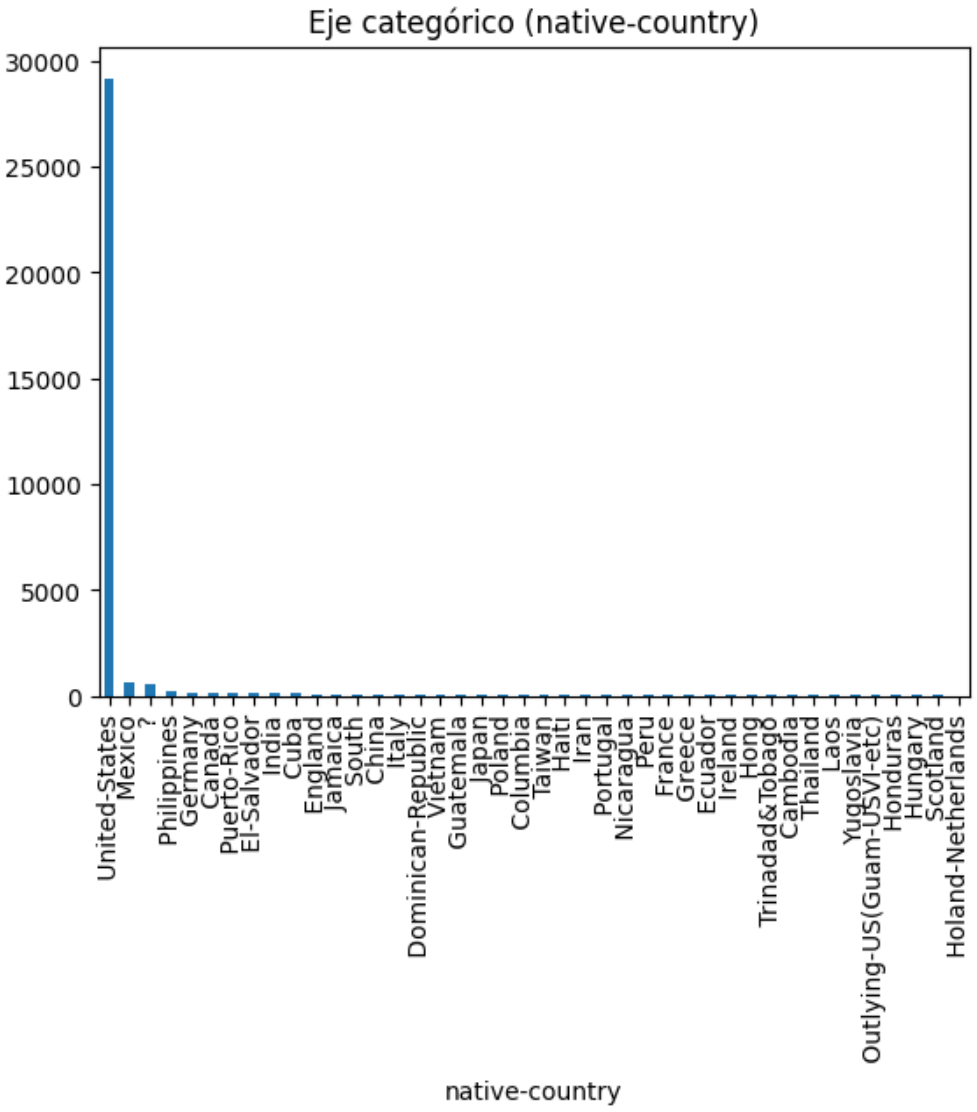

El país con mayor frecuencia son los E.U.A

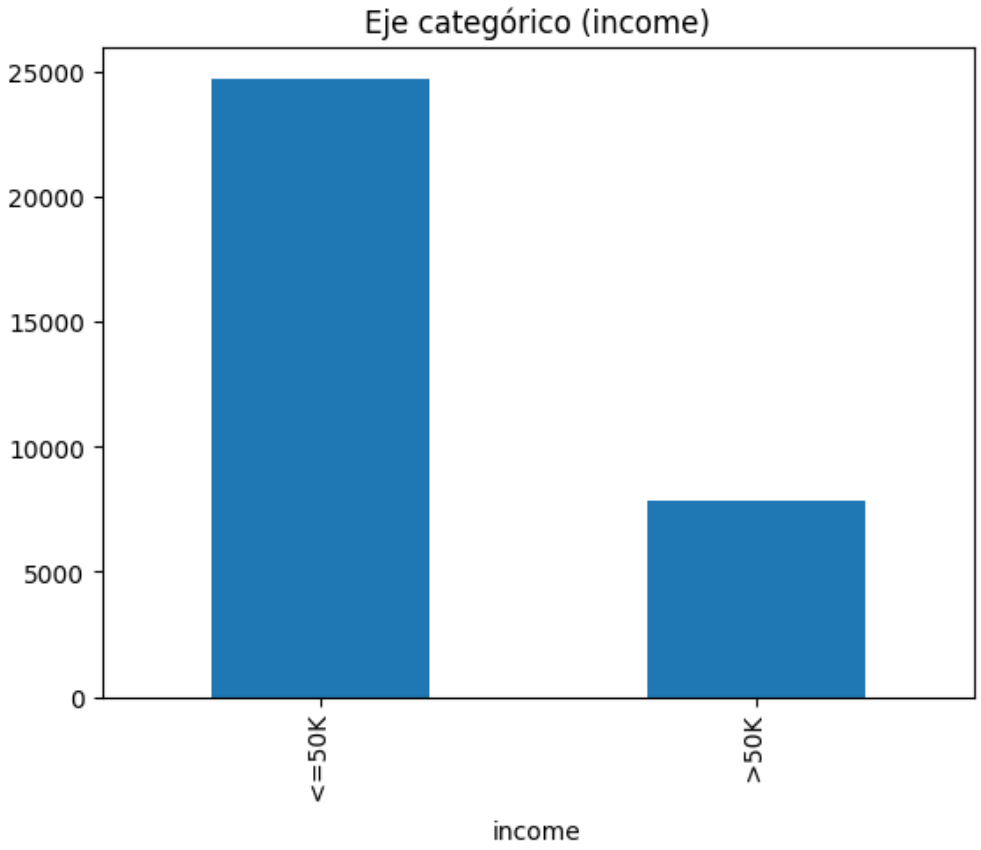

La mayor parte de las personas gana menos de 50000 dólares al año.

2.1. Mean encoding (centrado)

Procedemos a realizar la codificación para las variables categóricas, en este caso usaremos mean encoding centrado ya que esta codificación realiza un contraste directamente con la base, es decir la base cero para cada categoría es aquella categoría con mayor frecuencia, a continuación explicamos en que consiste:

- Se elige una categoría base (por ejemplo, la más frecuente o la de mayor peso).
- Se calcula la media global μ y la media de cada categoría μ_j
- En vez de usar μ_j directamente, se usa $\mu_j - \mu_{\text{base}}$
- Así, la base queda con (efecto cero), y el resto refleja el desvío respecto a ella.

Generamos las gráficas respecto a la diferencia de medias para cada categoría

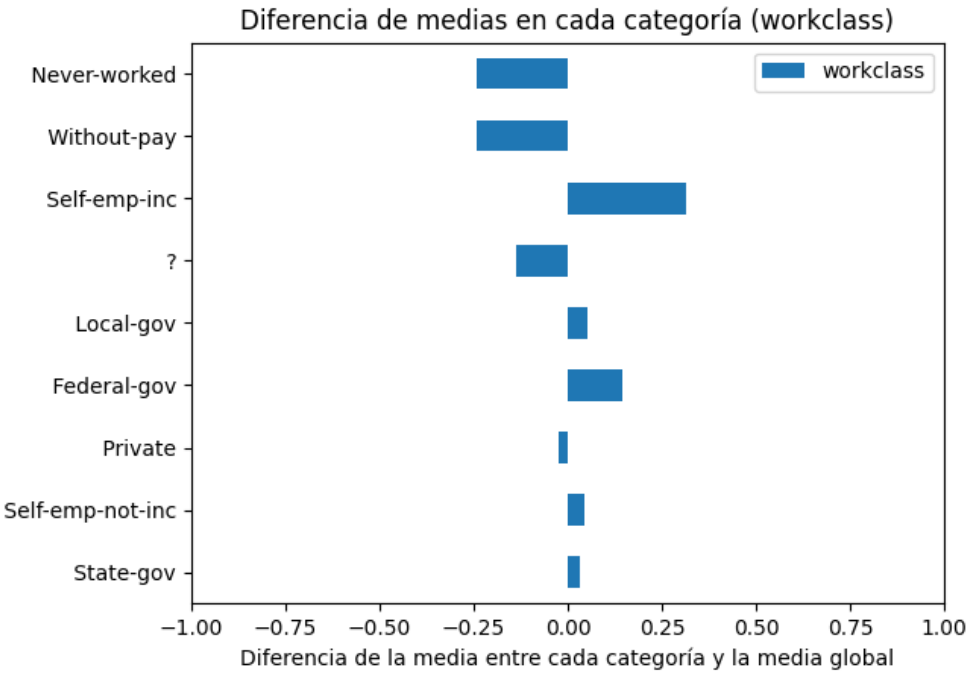

Para esta categoría tomamos como base cero a: Local-gov, Private, Self-emp-not-inc, State-gov ya que la diferencia esta muy cernana a cero

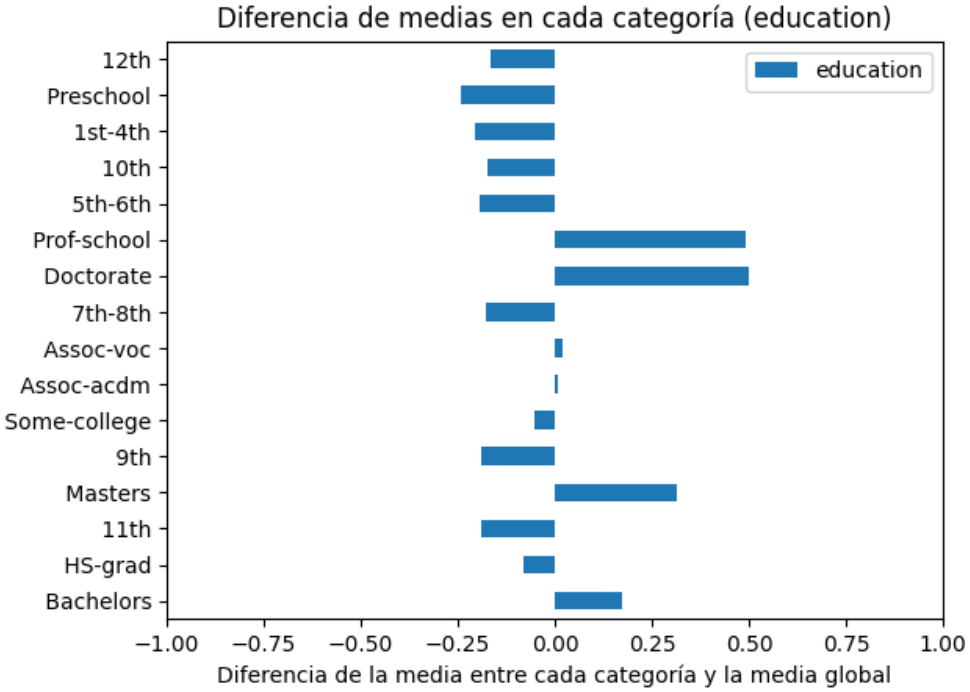

En este caso la base cero fue: Assoc-Voc, Assoc-acdm, y en las demás se realizó de forma analoga.

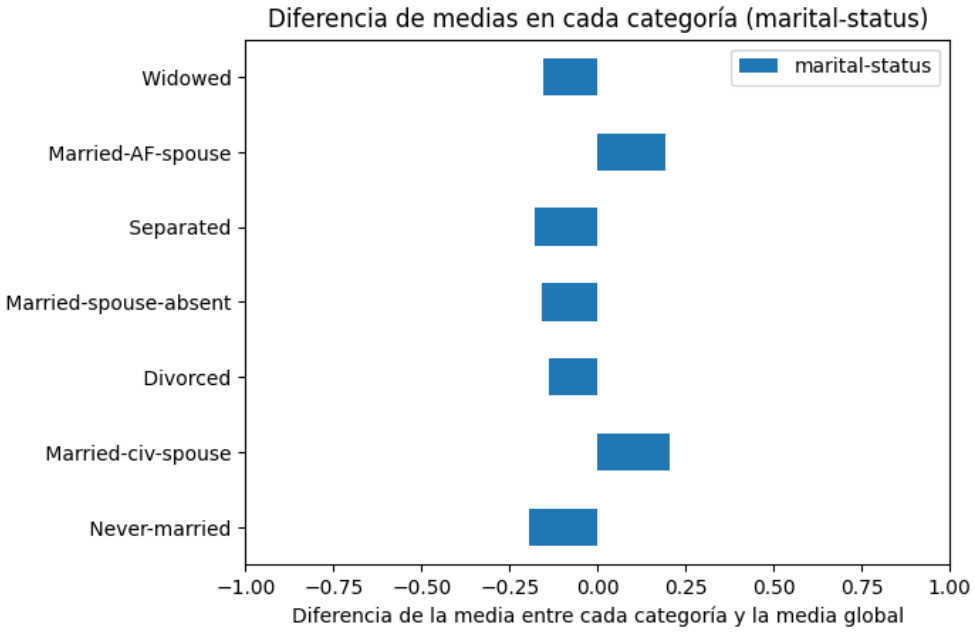
Diferencia de medias en cada categoría (marital-status)
marital-status
Widowed
Married-AF-spouse
Separated
Married-spouse-absent
Divorced
Married-civ-spouse
Never-married
−1.00
−0.75
−0.50
−0.25
0.00
0.25
0.50
0.75
1.00
Diferencia de la media entre cada categoría y la media global

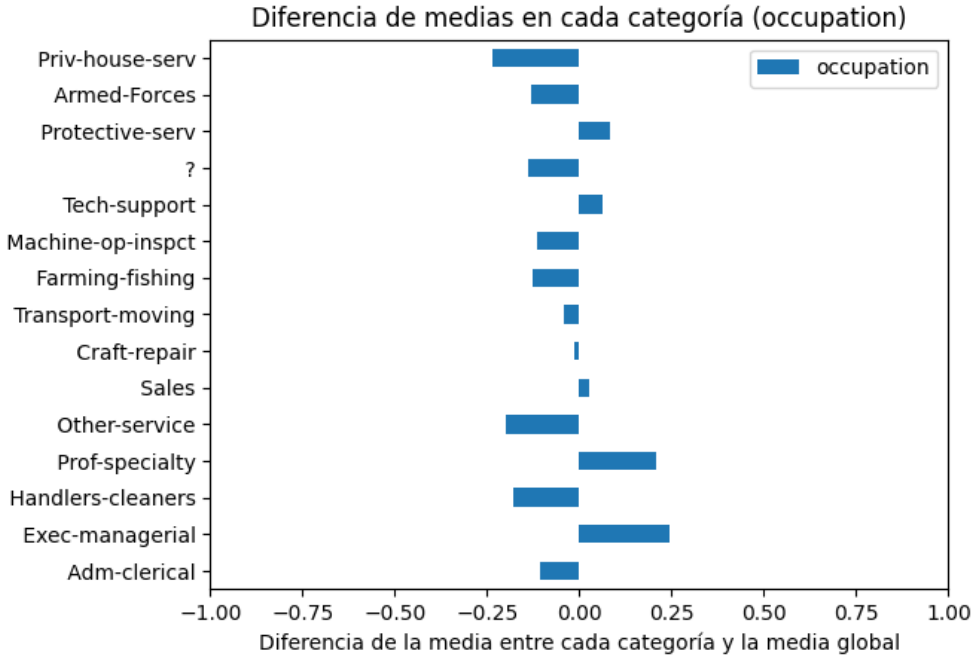
Diferencia de medias en cada categoría (occupation)
occupation
Priv-house-serv
Armed-Forces
Protective-serv
?
Tech-support
Machine-op-inspct
Farming-fishing
Transport-moving
Craft-repair
Sales
Other-service
Prof-specialty
Handlers-cleaners
Exec-managerial
Adm-clerical
−1.00
−0.75
−0.50
−0.25
0.00
0.25
0.50
0.75
1.00
Diferencia de la media entre cada categoría y la media global

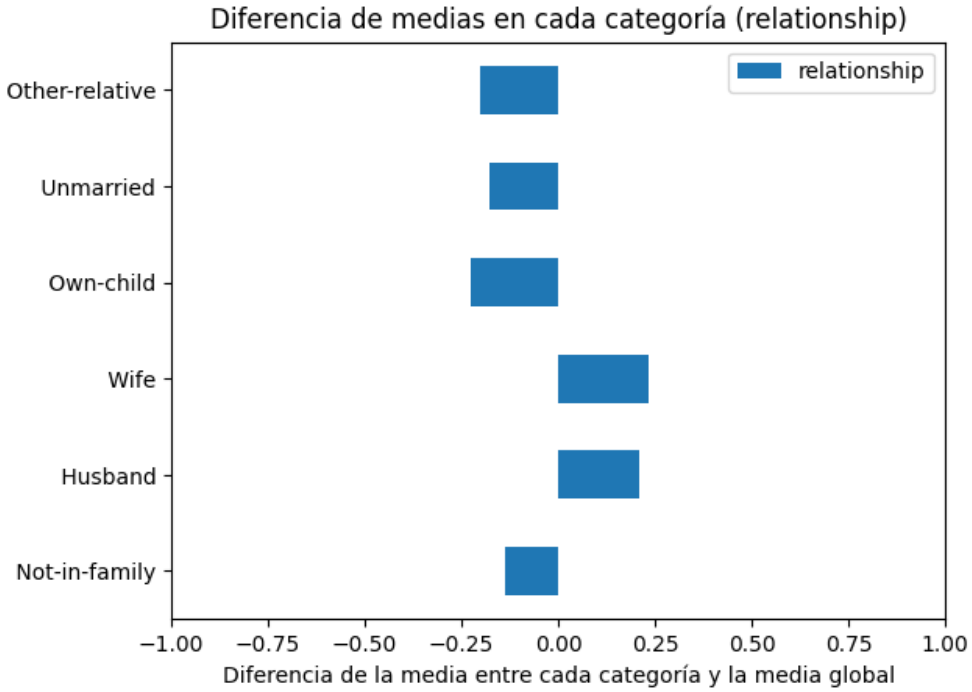
Diferencia de medias en cada categoría (relationship)
relationship
Other-relative
Unmarried
Own-child
Wife
Husband
Not-in-family
−1.00
−0.75
−0.50
−0.25
0.00
0.25
0.50
0.75
1.00
Diferencia de la media entre cada categoría y la media global

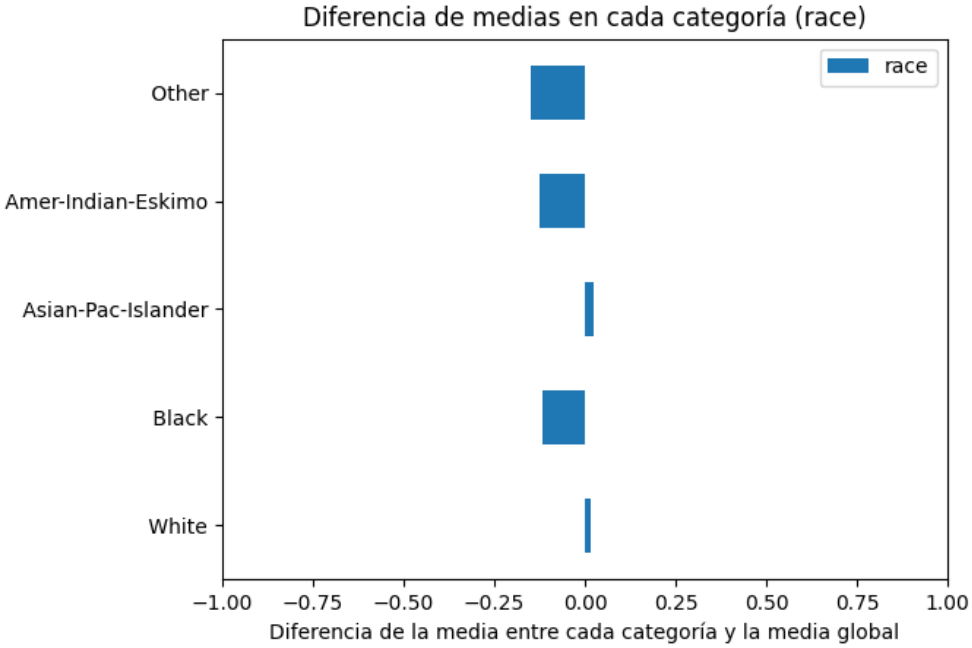
Diferencia de medias en cada categoría (race)
race
Other
Amer-Indian-Eskimo
Asian-Pac-Islander
Black
White
−1.00
−0.75
−0.50
−0.25
0.00
0.25
0.50
0.75
1.00
Diferencia de la media entre cada categoría y la media global

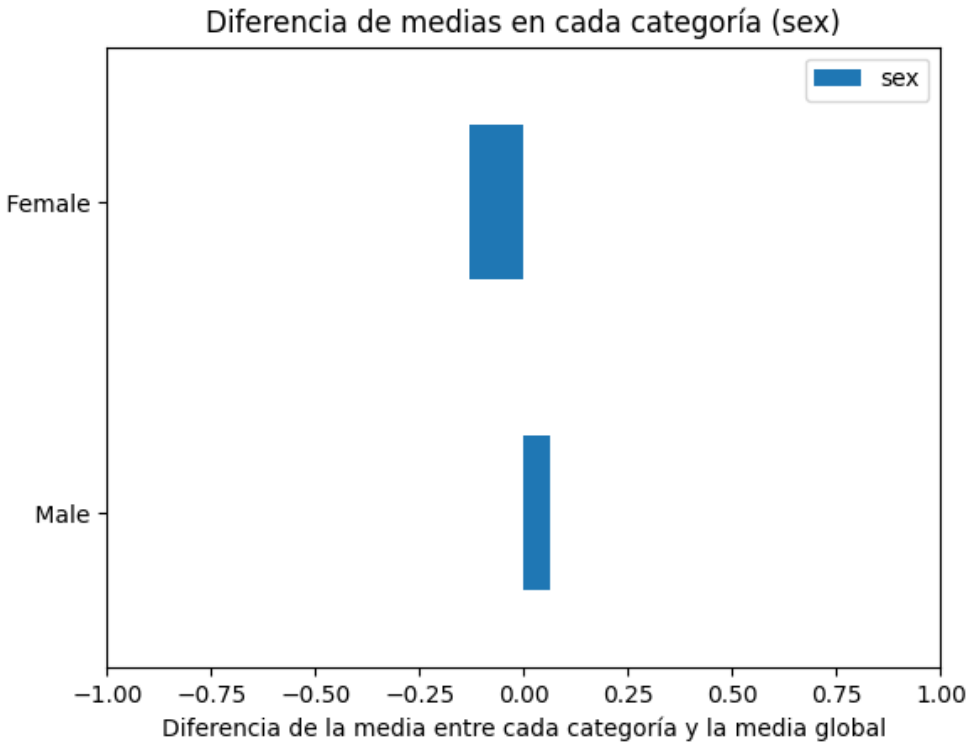

Una vez terminado la codificación mean encoding centrado, llegamos a un modelo con 27 covariables

3. Análisis - Modelos de Clasificación

En esta sección utilizamos los modelos de regresión logística, regresión logística Ridge, regresión logística Lasso, Naive Bayes Árboles de decisión, Bosques aleatorios, XGBoost y Support vectorial

Teniendo en cuenta las siguientes métricas:

Exactitud Proporción de predicciones correctas sobre el total de casos.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Precisión (Precision) Qué proporción de las predicciones positivas fueron correctas.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Sensibilidad (Recall o TPR) Qué proporción de los positivos reales fueron correctamente identificados.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Especificidad (TNR) Qué proporción de los negativos reales fueron correctamente identificados.

$$\text{Specificity} = \frac{TN}{TN + FP}$$

F1-score Media armónica entre precisión y recall.

$$\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

La matriz de confusión esta dada por:

$$\text{Matriz de Confusión} = \begin{bmatrix} TN & FP \\ FN & TP \end{bmatrix}$$

donde:

- TN: True Negatives (verdaderos negativos)
- FP: False Positives (falsos positivos)
- FN: False Negatives (falsos negativos)
- TP: True Positives (verdaderos positivos)

Resultados odemos observar la diferencia de la exactitud y el área bajo la curva ROC de los diferentes modelos:

Modelo	**Exactitud**	**AUC**
Logístico Simple	0.76	0.51
Logístico Lasso	0.76	0.51
Logístico Ridge	0.76	0.51
Naive Bayes	0.83	0.87
Árbol de Decisión	0.79	0.72
Bosque Aleatorio	0.83	0.88
XGBoost	0.85	0.90
Support Vector	0.85	0.90

Cuadro 1: Comparación de modelos de clasificación

Dado que los mejores modelos son XGBoost y Support vectorial, decidimos quedarnos con el modelo XGBoost para entrenarlo y realizar la clasificación.

4. Entrenamiento, validación cruzada del modelo XGBoost y Resultados

Utilizamos la técnica de búsqueda aleatoria para encontrar los hiperparámetros óptimos para realizar la clasificación, finalmente la exactitud (accuracy) obtenido para el modelo de clasificación usando XGBoost fue de 0.853

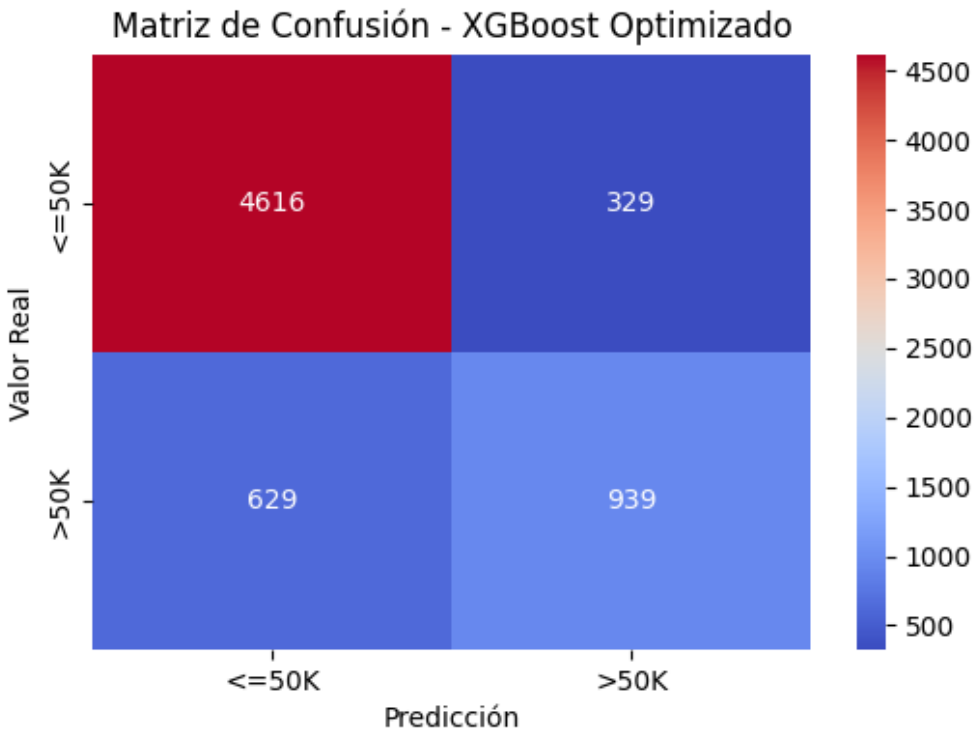

Métrica	Valor
Exactitud	0.852910
Precisión	0.740536
Sensibilidad	0.598852
Especificidad	0.933468
F1-Score	0.662200

Cuadro 2: Métricas de desempeño del modelo XGBoost optimizado

5. Conclusiones

Al final el modelo de clasificación nos dió un alto rendimiento predictivo, el modelo XGBoost logró una exactitud del 85.3 %, lo que indica un desempeño sólido al predecir si una persona gana más o menos de $50,000 al año, esto indica que las características socioeconómicas contenidas en el dataset tienen buen poder predictivo respecto al ingreso. De la matriz de confusión concluimos lo siguiente:

- Una precisión de 74.1 % implica que, entre las personas que el modelo predice como de altos ingresos, el 74.1 % realmente pertenece a esa categoría.
- La sensibilidad (59.9 %) muestra que el modelo detecta correctamente a casi el 60 % de las personas que efectivamente ganan más de $50,000, lo cual es aceptable pero deja espacio para mejoras si el objetivo es minimizar falsos negativos.
- La especificidad elevada (93.3 %) indica que el modelo distingue con gran eficacia a las personas que no ganan más de $50,000.
- El F1-score de 66.2 % representa un equilibrio razonable entre precisión y sensibilidad, especialmente útil si existe cierto desbalance entre clases.

En conjunto, estos resultados reflejan un modelo que generaliza bien, con una alta capacidad para evitar falsos positivos, y un desempeño sólido que puede servir como base confiable en aplicaciones prácticas.

6. Anexo: Código en Python para Clasificación del Dataset Adult

```
import numpy
import pandas
import matplotlib.pyplot as pyplot
import seaborn

adult = pandas.read_csv("adult.data", header=None)

adult.columns = [
"age", "workclass", "fnlwgt", "education", "education-num", "marital-status"
    ,
"occupation", "relationship", "race", "sex", "capital-gain", "capital-loss",
"hours-per-week", "native-country", "income"]

adult.info()

for column in adult.columns:
if adult[column].dtype == object:
adult[column].value_counts().plot.bar()
pyplot.xlabel(column)
pyplot.title(f"Eje categ\'orico ({column})")
pyplot.show()
else:
adult[column].plot.box()
pyplot.xlabel(column)
pyplot.title(f"Eje num\'erico ({column})")
pyplot.show()

y = adult["income"].map({" <=50K": 0, " >50K": 1})

for column in adult.columns:
if column == "native-country" or column == "income":
continue
if adult[column].dtype != object:
continue

mu = y.mean()
categorias = adult[column].unique()
xj = pandas.DataFrame(numpy.zeros(len(categorias)), index=categorias,
    columns=[column])

for cat_j in categorias:
mu_j = y[adult[column] == cat_j].mean()
xj.loc[cat_j] = mu_j - mu

xj.plot.barh()
pyplot.title(f"Diferencia de medias en cada categor\'ia ({column})")
pyplot.xlabel("Diferencia de la media entre cada categor\'ia y la media
    global")
pyplot.xlim((-1, 1))
pyplot.show()

mu = y.mean()
categorias = adult["native-country"].unique()
xj = pandas.DataFrame(numpy.zeros_like(categorias), index=categorias,
    columns=["native-country"])

for cat_j in categorias:
mu_j = y[adult["native-country"] == cat_j].mean()
xj.loc[cat_j] = mu_j - mu

xj.plot.bar()

from sklearn.cluster import KMeans
clu = KMeans()
clu.fit(xj)
```

```
xj["clu"] = clu.labels_

def test_categorias(x, indices=[]):
categorias = x.unique()
s = numpy.zeros_like(x)
for j in indices:
cat_j = categorias[j]
s = s + (x == cat_j).astype(int)
return s

x1 = test_categorias(adult["workclass"], [8, 7])
x2 = test_categorias(adult["workclass"], [6])
x3 = test_categorias(adult["workclass"], [3])
x4 = test_categorias(adult["workclass"], [4, 0, 1])
x5 = test_categorias(adult["workclass"], [5])

x6 = test_categorias(adult["education"], [9, 10])
x7 = test_categorias(adult["education"], [3, 0])
x8 = test_categorias(adult["education"], [14, 13, 11])
x9 = test_categorias(adult["education"], [8, 4, 12, 2, 15])

x10 = test_categorias(adult["marital-status"], [5, 1])

x11 = test_categorias(adult["occupation"], [14, 4, 2])
x12 = test_categorias(adult["occupation"], [3, 1])
x13 = test_categorias(adult["occupation"], [12, 10, 5])
x14 = test_categorias(adult["occupation"], [2, 1])
x15 = test_categorias(adult["race"], [4, 3, 1])
x16 = test_categorias(adult["sex"], [1])
x17 = test_categorias(adult["native-country"], [12, 26, 3, 21, 29, 30, 17])
x18 = test_categorias(adult["native-country"], [14, 9, 10, 11, 13, 38])
x19 = test_categorias(adult["native-country"], [18, 19, 2, 20, 23, 34, 7,
    22])
x20 = test_categorias(adult["native-country"], [25, 8, 37, 31, 36, 5, 27])
x21 = test_categorias(adult["native-country"], [16, 24, 32, 41])

def winzorizado(x):
Q1 = x.quantile(0.25)
Q3 = x.quantile(0.75)
IQR = Q3 - Q1
xmin = Q1 - 1.5 * IQR
xmax = Q3 + 1.5 * IQR
xp = (x < xmin) * xmin + ((x >= xmin) & (x <= xmax)) * x + (x > xmax) * xmax
return xp

x22 = winzorizado(adult["age"])
x23 = winzorizado(adult["fnlwgt"])
x24 = winzorizado(adult["education-num"])
x25 = (adult["capital-gain"] > 0).astype(int)
x26 = (adult["capital-loss"] > 0).astype(int)
x27 = winzorizado(adult["hours-per-week"])

X = pandas.DataFrame([
x1, x2, x3, x4, x5, x6, x7, x8, x9, x10,
x11, x12, x13, x14, x15, x16, x17, x18, x19, x20,
x21, x22, x23, x24, x25, x26, x27
], index=[
"x1", "x2", "x3", "x4", "x5", "x6", "x7", "x8", "x9", "x10",
"x11", "x12", "x13", "x14", "x15", "x16", "x17", "x18", "x19", "x20",
"x21", "x22", "x23", "x24", "x25", "x26", "x27"
]).T

from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, roc_curve, auc
from sklearn.linear_model import LogisticRegression
from sklearn.naive_bayes import BernoulliNB
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
```

```
from sklearn.svm import SVC
from xgboost import XGBClassifier
from sklearn.model_selection import RandomizedSearchCV
from sklearn.metrics import accuracy_score
import seaborn as sns
import matplotlib.pyplot as plt

X_train, X_test, y_train, y_test = train_test_split(X, y,
train_size=0.8, random_state=123, stratify=y)

cv = RandomizedSearchCV(
XGBClassifier(),
param_distributions={
        "max_depth": [None, 10, 100],
        "max_leaves": [4, 6, 8]
}
)

cv.fit(X_train, y_train)
mejores_params = cv.best_params_

clf_optimizado = XGBClassifier(
**mejores_params,
eval_metric="logloss",
random_state=123
)

clf_optimizado.fit(X_train, y_train)
y_pred = clf_optimizado.predict(X_test)

C = confusion_matrix(y_test, y_pred)
TN, FP, FN, TP = C.ravel()

plt.figure(figsize=(6, 4))
sns.heatmap(C, annot=True, fmt="d", cmap="coolwarm", xticklabels=["<=50K", "
    >50K"], yticklabels=["<=50K", ">50K"])
plt.xlabel("Predicci\'on")
plt.ylabel("Valor Real")
plt.title("Matriz de Confusi\'on - XGBoost Optimizado")
plt.show()

exactitud = (TN + TP) / (TN + FP + FN + TP)
precision = TP / (TP + FP)
sensibilidad = TP / (TP + FN)
especificidad = TN / (TN + FP)
f1 = 2 * (precision * sensibilidad) / (precision + sensibilidad)

pd.DataFrame(
[exactitud, precision, sensibilidad, especificidad, f1],
index=["Exactitud", "Precisi\'on", "Sensibilidad", "Especificidad", "F1-
    Score"],
columns=["Valor"]
)
```